PROJECT: “DATA STRUCTURES 2026”

PART I: “Sorting and Searching Algorithms”

Στην ιστοσελίδα **https://www.stats.govt.nz/large-datasets/csv-files-for-download/** υπάρχουν δεδομένα για ανάλυση/επεξεργασία σε αρχεία csv που αφορούν τους ακόλουθους τομείς: Business, Census, Economy, Effects of COVID-19 on trade , Environment, Government finance, Health, Industries, Labour market, Population, Society. Στην παρούσα εργασία θα ασχοληθούμε με δεδομένα από το Effects of COVID-19 on trade, και συγκεκριμένα το “dataset effects-of-covid-19-on-trade-at-15-december-2021-provisional.csv” (**https://www.stats.govt.nz/information-releases/effects-of-covid-19-on-trade-at-15-december-2021-provisional**) , το οποίο περιέχει συνολικά 111.438 εγγραφές, με την ακόλουθη δομή:

Direction	Year	Date	Weekday	Country	Commodity	Transport_Mode	Measure	Value	Cumulative

Το παραπάνω αρχείο λοιπόν περιέχει τα ακόλουθα πεδία: Direction {imports, exports , reimports}, Year {2015,…., 2021}, Date {01/01/2015, 01/02/2015,……, 15/12/2021}, Weekday {Monday,…., Sunday}, Country {All, China, European Union, Asia, Australia, USA,…..}, Commodity {“All”,
“Milk powder, butter, and cheese”, “Fish, crustaceans, and molluscs”, “Non-food manufactured goods”, “Electrical machinery and equip”,…….}, Transport_Mode {All, sea, air, …}, Measure { $, Tonnes, …}, Value {long integer που αντιπροσωπεύει την τιμή/unit εμπορεύματος σε δολάρια ή τόνους}, Cumulative {long integer που αναπαριστά την συσσωρευτική τιμή των μονάδων εμπορεύματος που διακινήθηκαν σε δολάρια ή τόνους}.

Σας ζητείται να υλοποιήσετε τέσσερα διαφορετικά προγράμματα σε γλώσσα C,C++ ή Java που να χρησιμοποιούν ως είσοδο το παραπάνω αρχείο και το καθένα να υλοποιεί τις παρακάτω λειτουργίες:

(1) Ταξινόμηση κατά αύξουσα σειρά των ημερομηνιών (Πεδίο **Date**) βάσει των τιμών του Πεδίου **Cumulative** κάνοντας χρήση των αλγορίθμων **Counting Sort** και **merge Sort**, σύμφωνα με τον ψευδοκώδικα που σας επεξηγήθηκε στη θεωρία (για λεπτομέρειες δείτε τις σχετικές διαφάνειες στο e-class). Συγκρίνατε πειραματικά τους δύο (2) αλγορίθμους. Τι παρατηρείτε?

(2) Ταξινόμηση κατά αύξουσα σειρά των ημερομηνιών βάσει των τιμών **Value** κάνοντας χρήση των αλγορίθμων **Heap Sort** και **Quick Sort**, σύμφωνα με τον ψευδοκώδικα που σας επεξηγήθηκε στη θεωρία (για λεπτομέρειες δείτε τις σχετικές διαφάνειες στο e-class). Συγκρίνατε πειραματικά τους δύο (2) αλγορίθμους. Τι παρατηρείτε?

(3) Εύρεση **value** ή/και **cumulative** για συγκεκριμένη ημερομηνία (**Date**) που θα δίνεται από το χρήστη, σύμφωνα με τους αλγορίθμους **Δυαδικής Αναζήτησης** και **Αναζήτησης με Παρεμβολή.** Τί παρατηρείτε ως προς τους χρόνους μέσης περίπτωσης? Πόσο η ΚΑΤΑΝΟΜΗ του Data Set επηρεάζει την απόδοση του κάθε αλγορίθμου?

(4) Υλοποιήστε το ζητούμενο του ερωτήματος (3) κάνοντας χρήση του αλγορίθμου **Δυικής Αναζήτησης Παρεμβολής (BIS)**. Συμβουλευτείτε τον ψευδοκώδικα της σελίδας 80 του βιβλίου «Δομές Δεδομένων», Α.Κ. Τσακαλίδης, Πανεπιστήμιο Πατρών, Τμήμα Μηχανικών Η/Υ και Πληροφορικής καθώς και το αρχείο *searching.pdf* που συνοδεύει την εκφώνηση. Επαληθεύστε πειραματικά τη χρονική πολυπλοκότητα που ισχύει για την μέση (expected) και χειρότερη περίπτωση (worst-case).Η βελτίωση της χειρότερης περίπτωσης επιτυγχάνεται με μία παραλλαγή του BIS. Συμβουλευτείτε τη σελίδα 83 του βιβλίου «Δομές Δεδομένων», Α.Κ. Τσακαλίδης, Πανεπιστήμιο Πατρών, Τμήμα Μηχανικών Η/Υ και Πληροφορικής καθώς και τις διαφάνειες *searching.pdf* και υλοποιήστε τον αλγόριθμο της συγκεκριμένης παραλλαγής (**BIS*).** Συγκρίνατε πειραματικά τους παραπάνω δύο αλγορίθμους (BIS και BIS*). Τί παρατηρείτε ως προς τους χρόνους χειρότερης περίπτωσης?

Bonus1: Η απλή εμπειρική προσέγγιση λέει ότι αν μετά από 3 (~2.4) άλματα μεγέθους $\sqrt{n}$,όπως ορίζει ο BIS, δεν εντοπιστεί η σωστή $\sqrt{n} - \acute{\alpha}\delta\alpha$, τότε με μεγάλη πιθανότητα η κατανομή δεν είναι uniform, και επομένως πρέπει να μεταβούμε στην παραλλαγή του (δηλαδή στον BIS*) κάνοντας $2^i\sqrt{n}$ άλματα για να εξασφαλίσουμε O (logn) στη χειρότερη περίπτωση. Μία πιο αποδοτική προσέγγιση θα ήταν να τρέξουμε σε 2 παράλληλα threads τον BIS και BIS*, και να συμβουλευθούμε τον πιο γρήγορο.

Bonus 2: Συμβουλευτείτε τις διαφάνειες του αρχείου LA-Searching.pdf, και υλοποιήστε 2 παράλληλα threads για να συγκρίνετε: BIS vs LA-BIS και BIS* vs LA-BIS*.

PART II: "BSTs (Balanced Search Trees) && HASHING"

Με τον κατάλληλο ορισμό δομών (structs) / κλάσεων (classes) και συναρτήσεων (functions) / μεθόδων (methods), να υλοποιήσετε μια εφαρμογή (σε γλώσσα C, C++ ή Java) που θα επεξεργάζεται τα δεδομένα του αρχείου **"**dataset effects-of-covid-19-on-trade-at-15-december-2021-provisional**.csv"**. Θυμίζουμε ξανά ότι κάθε γραμμή του αρχείου αυτού αντιστοιχεί σε μία ημέρα μετρήσεων, ενώ οι γραμμές έχουν την παρακάτω μορφή:

Direction Year Date Weekday Country Commodity Transport_Mode Measure Value Cumulative

(A) Η εφαρμογή διαβάζει αρχικά το αρχείο και δημιουργεί ένα **Δένδρο BST (Ισοζυγισμένο Δυαδικό Δέντρο)** στο οποίο κάθε κόμβος του διατηρεί την εγγραφή (Date, Cumulative της ημέρας αυτής). Το **BST** διατάσσεται ως προς την ΗΜΕΡΟΜΗΝΙΑ (Date) και υλοποιείται με δυναμική διαχείριση μνήμης. Προτιμότερες επιλογές AVL, red-black, (2,4) δέντρα. Μετά την δημιουργία του **BST** η εφαρμογή εμφανίζει ένα μενού με τις ακόλουθες επιλογές:

1. **Απεικόνιση** του **BST** με ενδο-διατεταγμένη διάσχιση. Κάθε απεικόνιση θα πρέπει να περιέχει μια επικεφαλίδα με τους τίτλους των στοιχείων των εγγραφών που απεικονίζονται.
2. **Αναζήτηση** της τιμής Cumulative βάσει ΗΜΕΡΟΜΗΝΙΑΣ (Date) που θα δίνεται από το χρήστη.
3. **Τροποποίηση** του περιεχομένου του πεδίου Cumulative που αντιστοιχεί σε συγκεκριμένη ΗΜΕΡΟΜΗΝΙΑ (Date).
4. **Διαγραφή** μιας εγγραφής που αντιστοιχεί σε συγκεκριμένη ΗΜΕΡΟΜΗΝΙΑ (Date).
5. **Έξοδος** από την εφαρμογή.

(B) Τροποποιήστε κατάλληλα τον κώδικα του (A), ώστε το αρχείο να διαβάζεται στο **BST** με βάση την τιμή του πεδίου Cumulative. Το **BST** διατάσσεται ως προς την τιμή Cumulative ανά ΗΜΕΡΟΜΗΝΙΑ (Date) και υλοποιείται με δυναμική διαχείριση μνήμης. Μετά την δημιουργία του **BST** η εφαρμογή εμφανίζει ένα μενού με τις ακόλουθες επιλογές:

1. Εύρεση ΗΜΕΡΑΣ/ΗΜΕΡΩΝ με την ΕΛΑΧΙΣΤΗ ΤΙΜΗ Cumulative.
2. Εύρεση ΗΜΕΡΑΣ/ΗΜΕΡΩΝ με τη ΜΕΓΙΣΤΗ ΤΙΜΗ Cumulative.

(Γ) Υλοποιήστε το (A) κάνοντας χρήση HASHING με αλυσίδες, αντί **BST**. Η συνάρτηση κατακερματισμού θα υπολογίζεται ως το υπόλοιπο (modulo) της διαίρεσης του αθροίσματος των κωδικών ASCII των επιμέρους χαρακτήρων που απαρτίζουν την ΗΜΕΡΟΜΗΝΙΑ με ένα περιττό αριθμό m που συμβολίζει το πλήθος των κάδων (buckets). Π.χ. για ΗΜΕΡΟΜΗΝΙΑ=" 15/12/2021" και m=11, ισχύει:

Hash("15/12/2021")= [ASCII('1')+ ASCII('5')+ ASCII('/')+ ASCII('1')+ ASCII('2')+ ASCII('/')+ ASCII('2')+ ASCII('0')+ ASCII('2')+ ASCII('1')] mod 11.

Το πρόγραμμα θα εμφανίζει ένα μενού με τις ακόλουθες επιλογές:

1. **Αναζήτηση** Τιμής Cumulative βάσει της ΗΜΕΡΟΜΗΝΙΑΣ που θα δίνεται από το χρήστη.
2. **Τροποποίηση** των στοιχείων εγγραφής βάσει ΗΜΕΡΟΜΗΝΙΑΣ που θα δίνεται από το χρήστη. Η τροποποίηση προφανώς αφορά ΜΟΝΟ το πεδίο Cumulative.
3. **Διαγραφή** μιας εγγραφής από τον πίνακα κατακερματισμού βάσει ΗΜΕΡΟΜΗΝΙΑΣ που θα δίνεται από το χρήστη.
4. **Έξοδος** από την εφαρμογή.

Ενοποιήστε τα (Α), (Β) και (Γ) σε ένα πρόγραμμα στο οποίο ο χρήστης θα ερωτάται αν θέλει τη φόρτωση του αρχείου σε ένα **BST** ή σε μία δομή **Hashing** με αλυσίδες και στην περίπτωση που ο χρήστης επιλέξει το πρώτο να μπορεί εν συνεχεία να επιλέξει αν η φόρτωση στο **BST** θα γίνει με βάση την ΗΜΕΡΟΜΗΝΙΑ ή την τιμή Cumulative ανά ημέρα.

DEADLINE: ΗΜΕΡΟΜΗΝΙΑ ΕΞΕΤΑΣΗΣ ΕΑΡΙΝΟΥ ΕΞΑΜΗΝΟΥ

Η παράδοση της άσκησης θα πραγματοποιείται με ΑΝΑΡΤΗΣΗ ΣΤΟ Ε_CLASS και με αποστολή μηνύματος ηλεκτρονικού ταχυδρομείου ΚΑΙ ΣΤΙΣ ΤΡΕΙΣ ακόλουθες διευθύνσεις με ένα μήνυμα (με τρεις παραλήπτες και όχι τρια διακριτά μηνύματα): **sioutas@ceid.upatras.gr**, **makri@ceid.upatras.gr**, **lykothanasi@ceid.upatras.gr.**

Μπορείτε να συντάξετε την αναφορά σας σε όποια μορφή κειμένου επιθυμείτε (word, pdf, κ.λπ.). Στο ηλεκτρονικό μήνυμα που θα αποστείλετε θα έχετε συμπιεσμένα το αρχείο της αναφοράς σας καθώς και τα αρχεία των προγραμμάτων C, C++ ή Java.

ΑΡΙΘΜΟΣ ΦΟΙΤΗΤΩΝ ΑΝΑ ΟΜΑΔΑ <=4 (ίδια ομάδα με την πρώτη εργαστηριακή άσκηση)

ΠΟΣΟΣΤΟ ΕΠΙ ΤΟΥ ΣΥΝΟΛΙΚΟΥ ΒΑΘΜΟΥ: 20%+5%BONUS1+5%BONUS2 (το υπόλοιπο 10% είναι από την πρώτη εργαστηριακή άσκηση(

ΚΑΛΗ ΕΠΙΤΥΧΙΑ!!!